

模型专业能力测试

科研问答模型微调效果阶段性测试说明

日期：2026 年 9 月 13 日

本项目面向人工智能领域的论文阅读与专业问答，要求模型根据提供的论文材料，准确、完整地回答问题，并避免补充缺乏依据的研究结论。

前期测试**未能清楚展示微调收益及其与项目需求的关系**。后续核对了训练数据范围，完成新一轮训练，并针对回答遗漏完善提示词。

本次进一步细化评价方法，说明已有收益与改进方向。

本次由 GPT-6 Astra 在高推理强度设置下评价 300 道题的已有回答。**三项同时达标的回答，SFT 为 267 条，Base 为 236 条。**

结果支持 SFT 的正面效果：正确性和证据忠实性更好，完整性略低于 Base。

一、测试目的与范围

本次测试关注微调是否提高了有证据科研问答的质量。每道题提供问题和相关论文片段，要求模型据此作答，内容涉及研究事实、方法、实验比较和适用条件。

前期评测发现，部分回答虽然内容正确，却遗漏了必要解释、条件或子问题。为此，在作答前加入统一的任务说明，要求完整回应问题，并避免无依据扩写。

这段说明称为**回答提示词**，本次使用的版本记为 **Prompt V1**。例如，题目同时询问方法原理和适用条件时，提示词要求覆盖两部分。

提示词不包含具体答案，也不改变模型参数。**Base 与 SFT 使用相同的问题、论文材料和提示词**，以保持比较条件一致。

本轮只评价已经生成的回答，没有修改题目或重新生成答案。测试结果反映这组科研问答的表现，不直接代表模型在所有科研任务上的能力。

二、测试前已完成的工作

本次使用的模型经过以下训练与调整：

阶段	工作内容与作用
早期训练	最初使用 1,920 条数据 开展监督微调，形成早期模型及评测结果。
完整数据训练	后续基于完整的 2,000 条数据 训练 RUN002，其中 1,900 条用于训练、100 条用于验证。验证数据用于检查参数学习。
完善回答提示词	针对评测中发现的遗漏问题，加入 Prompt V1，要求模型覆盖各个子问题、必要机制和条件，同时避免无依据后的模型更充分地发挥已有能力。
统一条件比较	Base 与 SFT 均使用相同提示词，在相同的 300 道题上比较，避免因任务说明不同而影响结果解释。

三、评价方法

科研问答中的数值错误、条件遗漏或无依据解释，都可能影响论文理解。

因此，评价分别检查**内容是否准确、问题是否完整、陈述是否有据**，并单独考察表达是否清楚。

1. 评价维度

评价维度	检查内容	设置依据
事实与关系正确性	数值、研究对象、方法关系、比较方向和条件是否准确，是否将推测表述为确定结论	科研问答需要准确传达研究内容，局部错误也可能影响阅读理解
问题完成度	是否回答全部子问题，并覆盖所要求的机制、条件、比较维度和结果	只回答部分内容，即使已写出的内容正确，也可能没有完
证据忠实性	关于研究的陈述是否得到所给论文材料支持，是否添加材料未提供的解释或结论	看似合理的解释不一定来自论文，需要区分材料支持的内容
表达与指令遵循	表述和指代是否清楚，是否遵守题目要求的输出形式	回答需要便于理解和使用，但表达流畅本身不能证明内容

评审先列出**必答点，即完成该题必须包含的信息**，再检查答案是否覆盖，避免按篇幅或整体印象判断完整性。

询问数值时无需增加背景；要求解释原因时，应交代必要机制。允许准确转述，不要求逐字复述。

每个维度分为“达标”“部分达标”“不达标”和“无法判断”。局部缺陷与影响任务完成的关键缺陷分别记录；材料不足时保留不确定性，**不直接判为事实错误**。

2. 主指标与辅助比较

单一总分可能掩盖缺陷。数值错误或整项漏答，不应被流畅的表达抵消。因此，主指标要求三项内容标准同时满足：

完整且可靠的回答比例 = 正确性、问题完成度、证据忠实性三项同时达标的题数 ÷ 300。

这一指标反映满足科研问答基本要求的回答比例，表达质量单独报告。若材料不足，答案应说明限制，不应自行补充研究结论。

成对比较逐题判断 SFT 更优、Base 更优、平局或无法确定。它作为辅助指标，因为**优于另一份答案，不等于已经完成任务**。

只有存在实质质量差异时才判一方更优。平局可能表示双方均充分，也可能表示双方有相近不足，需要结合分项结果理解。

四、测试结果

1. 各项达标情况

指标	Base	SFT
事实与关系正确性	250/300 (83.33%)	288/300 (96.00%)
问题完成度	278/300 (92.67%)	271/300 (90.33%)
证据忠实性	240/300 (80.00%)	287/300 (95.67%)
表达与指令遵循	297/300 (99.00%)	300/300 (100.00%)
前三项同时达标	236/300 (78.67%)	267/300 (89.00%)

按本次模型评审，SFT 比 Base 多了 31 条同时正确、完整、有据的回答，**三项同时达标率提高 10.33 个百分点**。

这一比例不等同于单独的事实准确率。分项结果显示，优势主要来自正确性和证据忠实性。

完整性方面，SFT 达标题数比 Base **少 7 条**，部分回答仍遗漏必要内容。

多数未达标项属于局部缺陷，不代表整题错误。同一回答可能涉及多个维度的问题，各项数量不能直接相加。

2. 成对比较结果

结果	条数	占比
SFT 更优	46	15.33%
Base 更优	12	4.00%
平局	241	80.33%
无法确定	1	0.33%

SFT 被判为更优的次数多于 Base，与主指标的结果一致。其余多数题目为平局，评审未发现足以区分优劣的实质差距。

3. 典型表现

完整说明方法，不额外夸大效果。 一道方法流程题中，SFT 完整回答了编码方式和解码过程。Base 也覆盖了这些内容，但额外宣称方法已解决准确性和效率问题，缺少材料支持，因此评审更认可 SFT。

保留论文结论的确定程度。 一道方法局限性题中，SFT 完整说明了策略及其后果，并保留原文的“可能”表述。Base 将风险写成必然结果。SFT 的解释更符合论文原意。

准确回应问题，避免解释引入错误。 一道阈值题同时询问最小值和平均值条件，SFT 准确给出两项要求。Base 的数值也正确，但补充说明混淆了指标定义，SFT 因而被判为更优。

多子问题的覆盖仍需改善。 一道题同时询问计算预算和模型规模，SFT 只回答了预算部分。这类遗漏说明，后续应在保持准确性和证据忠实性的同时，加强必要内容的覆盖。

五、对 Grok 旧评测的补充与完善

此前的测试使用 Grok-4.5 作为评审模型，采用十分制评分和双序成对比较。双序比较是指交换两份答案的展示顺序后再次评价，检查判断是否一致。旧报告结果如下：

成对比较结果	条数	占有效记录比例
Base 明确更优	21	7.00%
SFT 明确更优	23	7.70%
两次均判等价	166	55.50%
交换顺序后判断冲突	89	29.80%
双方均不可接受	0	0%

旧测试有 299 条有效记录，另 1 条因评审输出格式错误未纳入统计。上表以 299 条为分母。

十分制评分	Base	SFT
平均分	9.181	9.181
分数离散程度 (标准差)	0.818	0.896

1. 从初步比较转向具体问题分析

旧评测已考虑正确性、完整性和证据忠实性，但主要以总分和胜负呈现。**约 86% 的样本集中在 9—10 分**，难以从均分判断具体改善或缺陷。

旧结果未能支持明确的微调收益，同时暴露了双序判断不一致的问题。这些记录均予以保留。

本次在此基础上检查**正确、完整、有据是否同时成立**，补充各维度的达标情况，使收益与不足都能对应到具体的科研问答要求。

2. 必答点使改进方向更明确

本次逐项记录题目要求及答案覆盖情况，具体指出模型规模子问题的遗漏、原因解释不充分等问题，为后续训练提供依据。

旧评测有 89 条顺序冲突，限制了结论的确定性。本次补充任务达标比例与逐项缺陷分析，用于判断模型是否完成科研问答要求；这些补充不等于已经解决旧评测暴露的全部问题。

3. 新指标与项目目标联系更紧密

本次评价依据来自项目对准确性、完整性和证据支持的要求。相同标准也记录了 SFT 的不足：**同时达标的回答多 31 条，完整性单项少 7 条**。这有助于判断已有改进是否有效，并确定仍需补足的内容。

两次评审模型不同，旧测试的受测模型版本、提示词及回答是否与本次一致也尚未核实，**结果差异不能全部归因于指标调整**。

本次未逐题交换顺序复评。新指标更贴合项目目标，不代表每条新判断都更准确。

六、结论与后续改进进展

本次模型评审为 RUN002 SFT 提供了正面的阶段性证据。 在相同条件下，SFT 有更多回答同时正确、完整、有据，更贴近项目需求。

围绕前期评测发现的同类问题，下一轮训练的数据准备与生成试验已经开展。主要工作如下：

已完成的工作	内容与进展
复查现有训练数据	对 50 条重点训练样本 逐项核对问题、答案和论文材料，检查必要内容及比较条件。这些是训 300 道测试题不同。
完善训练数据生成要求	调整用于生成训练问答的提示词，强调机制、条件和多子问题的覆盖；在小样本试验中取消以 限制，避免仅因篇幅排除较完整的回答。
完成小样本生成与复查	已在 30 份论文材料上开展生成试验，并复查产出。结果中既有包含机制和比较关系的问答， 足、关系归属错误等问题。
验证不同生成方式	对直接生成问答、先出题再独立回答等方式进行了小规模对照。自动生成能够保留部分科研步 分步骤尚未显示明确优势。

训练样本复查中，模型辅助审查对 48 条未发现当前问题范围内的实质缺陷，另 2 条涉及比较条件遗漏 或比较依据不足。这说明**不能将短答案一概视为质量问题**，改进应针对实际缺失的内容。

上述工作已将完整性问题落实到训练数据的选题、生成和检查环节。

下一步重点是确认候选训练数据的质量与覆盖范围，再通过训练对照检验是否减少遗漏。同时，仍需 对本次模型评审的主要收益和争议判定进行人工抽查。